

实践项目任务书（三）

一、项目基本信息

项目名称： 短视频广告虚假宣传话术检测系统

项目方向： AI 辅助自然语言处理与内容风险识别

主要技术： 视频音频提取、中文语音识别（ASR）、光学字符识别（OCR）、关键词与正则规则、语言模型（LM）分类、多标签文本分类、证据抽取、结果评价、AI 辅助开发。

项目规模： 3-4 人/组。

二、项目背景说明

直播带货和短视频广告中常出现商品口播、字幕、商品标题、评论区引导等多种文字信息。部分广告可能使用“行业天花板”“根治”“速效”“无效退款”“稳赚”“保本”“日入”“最后几单”“扫码加群”等表达，对消费者形成绝对化、夸大功效、收益承诺、促销误导、诱导消费或站外导流等风险线索。实际审核不能只给出“有风险”或“无风险”的结论，还应当保留原始证据、出现位置和可供人工复核的解释。

违规类型	细分类型	例子
功效夸大	根治、速效、无效退款、绝对化描述、非医疗用品宣称医疗功能	“七天根治”“一用就好”、“消渴茶能治糖尿病”、“最顶尖设计”
收益承诺	稳赚、保本、日入	“月入过万”“稳赚不赔”
价格或促销误导	原价虚构、限时稀缺	“最后 3 单”“全网最低价”
私域/站外导流	私信、加群、扫码	“加微信领取资料”
正常或无法判断	有条件描述、普通商品介绍	“适合部分人群，效果因人而异”

本实践项目要求以公开直播回放或短视频广告片段为输入，完成视频音频提取、语音转写、画面文字识别、文本合并、规则基线检测和语言模型风险分类等工作，构建一个可供人工审核的视频广告虚假宣传话术检测系统。系统应将广告切片分

类为“正常”“存在某类风险线索”或“无法判断”，并输出风险类别、证据文本、时间戳或文本位置、规则依据和解释。

项目重点是完成“视频处理 → ASR/OCR 文本获取 → 文本风险分类 → 证据抽取 → 效果评价 → Demo 展示”的完整过程，理解语言模型如何处理实际内容审核问题，并能够借助 AI 完成代码编写、调试、提示词设计和结果分析。

三、项目主要任务

通过本实践项目，具体完成以下主要工作：

1、准备视频广告样本。使用教师提供和自行收集的直播回放、短视频广告片段。

准备不少于 200 条短视频广告切片。每条样本应记录 `sample_id`、视频标题、商品/服务类别、来源与采集日期、视频时长等基本信息。

2、建立标签体系和人工标注表。至少建立以下 6 类标签：正常、存在夸大功效、存在虚假收益承诺、存在诱导消费、存在站外导流风险线索、存在其他线索。一条样本可具有多个标签。标注表至少包含 ASR 口播文本、字幕/OCR 文本、文案、风险标签、证据文本、证据时间戳或文本位置、人工说明等字段。

3、完成视频预处理与文字信息提取。对视频提取音频，使用 Whisper、FunASR 或等价中文语音识别工具获得带时间戳的口播转写文本；每隔 1–3 秒抽取视频帧，使用 PaddleOCR 或等价工具识别字幕、价格、促销信息、联系方式和二维码周边文字。对重复或明显无效的文本进行基本清洗与合并。

4、建立基线方法。将 ASR、OCR、文案等作为输入，构建基于小规模语言模型、小规模 LLM（如 Qwen8B）或其他类型的风险识别模型，不得直接使用大规模 LLM（如 28B）来进行虚假宣传**风险话术分类**，完成多标签分类。模型输出应采用结构化输出，至少包括 `risk_labels`、`risk_level`（可选）、`evidence`、

evidence_position、rule_basis 和 explanation (可选) 等字段。应要求模型以视频中可见文本、可听到的内容为依据, 不得推测商品实际效果。

6、完成性能评估。 在人工标注测试集上对构建的方法进行测试, 统计各类标签的 Precision、Recall 和 F1。随机抽取至少 20 条预测结果进行人工复核, 分析漏检、误检以及证据不充分的典型原因。

7、完成审核结果展示 Demo。 编写命令行程序、Notebook 或简单 Web 页面, 实现输入视频或选择样本后, 展示视频基本信息、ASR/OCR 文本、风险类别、原文证据、时间戳、规则依据和审核解释。Demo 不要求实现账号登录、在线爬取或自动处罚等功能。

8、完成一次简单改进。 可从增加同义表达与正则规则、改进文本清洗、加入少量样本示例、加入法规条款检索、优化提示词、调整风险等级规则等方向中选择一种, 比较改进前后的指标或典型案例效果。

9、标注与判断要求

(1) 以视频中可见、可听到的内容为准, 不推测商品实际效果或商家真实经营情况。

(2) 同一条样本允许多个标签。例如, “减肥产品 + 三天见效 + 私信下单”可同时标注“存在夸大功效”和“存在站外导流风险线索”。

(3) “可能”“有助于”“部分用户反馈”“效果因人而异”等有条件描述不必然构成风险, 应结合上下文标为“正常”或“无法判断”。

(4) 医疗、药品、保健食品、金融投资等高敏感领域, 应采用更严格的风险判断标准。

(5) 每一项风险结论均须对应原文证据和时间戳或文本位置；证据不足时应输出“无法判断”。

(6) 推荐采用“大模型辅助初标 + 人工复核”的方式形成最终标注。

四、详细实验过程与学时建议安排

1. 详细实验过程

- (1) 理解任务背景、风险标签和标注规则；
- (2) 确定公开样本来源并建立样本信息表；
- (3) 抽取部分样本完成初步人工标注；
- (4) 完成视频音频提取、ASR 转写和 OCR 识别；
- (5) 清洗并整合多来源文本；
- (6) 建立敏感词典与正则规则，完成规则基线；
- (7) 设计 LLM 提示词并实现结构化风险分类；
- (8) 输出证据文本、时间戳、规则依据和解释；
- (9) 构建测试集并对比规则方法与 LLM 方法；
- (10) 人工复核至少 20 条预测结果，分析误判案例；
- (11) 完成一次简单改进并验证效果；
- (12) 运行 Demo，整理实验报告和答辩材料。

3. 建议的最小实验记录

实验	方法/条件	测试样本数	Precision	Recall	F1	典型问题或结论
E1	关键词/规则基线					

实验	方法/条件	测试样本数 Precision Recall F1 典型问题或结论
E2	零样本或少样本分类	
E3	改进后	

建议另外保留人工复核记录表，至少包含：样本编号、人工标签、模型标签、证据是否正确、是否需要修改、误判原因。

五、提交的材料

以小组为单位，实践项目完成后提交以下材料：

- 1、完整的源代码。** 代码应能够直接运行，并至少包含视频/音频预处理、ASR 或可替代文本输入、OCR、规则检测、LLM 分类、证据输出、指标计算和 Demo 等主要功能。若受设备或网络条件限制无法运行 ASR/OCR，可提供已提取的文本及清晰的复现说明。
- 2、数据与标注文件。** 提交样本信息表、人工标注表和必要的 ASR/OCR 结果文件。视频原文件因体积、版权或隐私原因不便提交时，可提交公开链接、样本编号、关键帧、转写文本及获取说明。
- 3、不少于 10 页的实验报告（每人一份）。** 可按照项目主要任务组织内容，说明样本与标签设计、ASR/OCR 获取方式、规则基线、LLM 提示词设计、输出格式、方法对比结果、人工复核结果、典型正确与错误案例、一次简单改进及验证结果。
- 4、AI 协作记录。** 至少记录 2 条关键 AI 使用情况，说明“向 AI 提出了什么问题、AI 给出了什么建议、是否采用”。
- 5、小组分工说明。** 说明 3-4 名成员分别承担的主要工作。
- 6、答辩 ppt。**